DERİN ÖĞRENME KULLANARAK ZAMANSAL VE MEKANSAL SICAKLIK ANOMALİSİ TAHMİNİ

M. Selçuk İNCİ
Yapay Zeka ve Veri Mühendisliği
240711020
muhammedselcuk.inci24@ogr.atauni.edu.tr

1 Problemin Tanımı

İklim değişikliği nedeniyle sıcaklık örüntüleri zaman içerisinde değişmekte ve bu değişimler coğrafi bölgelere göre farklılık göstermektedir. Tek bir şehrin tarihsel sıcaklık verileriyle eğitilen modeller, farklı şehirlerdeki ortak sıcaklık örüntülerinden yararlanamayabilir.

Bu projede, farklı şehirlerin tarihsel sıcaklık anomalilerini ve coğrafi konum bilgilerini kullanan derin öğrenme modelleriyle gelecek 12 aylık sıcaklık anomalilerinin tahmin edilmesi amaçlanmaktadır.

Araştırmamız; Coğrafi konum bilgisini ve farklı şehirlerin tarihsel sıcaklık örüntülerini birlikte öğrenen bir model, tek şehirli modellere kıyasla daha doğru tahminler üretebilir mi sorusuna odaklanacak.

2 Motivasyon

Sıcaklık anomalileri, gözlemlenen sıcaklıkların belirli bir referans döneminin ortalamalarından sapmasını ifade eder ve uzun vadeli iklim değişimlerinin incelenmesinde önemli bir göstergedir.

Farklı coğrafi bölgeler arasında ortak sıcaklık örüntülerinin bulunması, çok şehirli modellerin tek şehirli modellere göre avantaj sağlayabileceğini düşündürmektedir. LSTM ve GRU gibi derin öğrenme mimarileri, zaman serilerindeki karmaşık ve doğrusal olmayan ilişkileri öğrenme potansiyeline sahiptir.

Bu çalışmanın motivasyonu, çok şehirli ortak öğrenmenin ve coğrafi konum bilgisinin tahmin performansına katkısını araştırmak ve modellerin farklı coğrafi bölgelerdeki genelleme yeteneklerini değerlendirmektir.

3 Veri Seti

Projede, Berkeley Earth tarafından sağlanan ve Kaggle üzerinde yayımlanan Climate Change: Earth Surface Temperature Data veri seti kullanılacaktır.

Dataset: Berkeley Earth – Climate Change: Earth Surface Temperature Data

Çalışmada özellikle GlobalLandTemperaturesByCity.csv dosyasından yararlanılacaktır. Bu dosya, dünya genelindeki şehirlerin tarihsel aylık ortalama sıcaklıklarını ve coğrafi bilgilerini içermektedir.

Veri setindeki başlıca değişkenler:

Değişken	Açıklama
dt	Ölçüm tarihi
AverageTemperature	Aylık ortalama sıcaklık (°C)
AverageTemperatureUncertainty	Sıcaklık tahmininin belisrsizliği
City	Şehir adı
Country	Ülke
Latitude	Enlem
Longitude	Boylam

4 Önerilen Yöntem

İlk aşamada veri temizleme, eksik değer analizi, sıcaklık anomalisi hesaplama ve normalizasyon işlemleri gerçekleştirilecektir. Ardından kayan pencere (sliding window) yöntemiyle geçmiş 60 aylık gözlemlerden gelecek 12 ayın sıcaklık anomalilerini tahmin etmeye yönelik örnekler oluşturulacaktır.

Veriler kronolojik olarak eğitim, doğrulama ve test kümelerine ayrılacaktır. Ayrıca bazı şehirler eğitim dışında tutularak modellerin görülmemiş coğrafi konumlardaki performansları değerlendirilecektir.

Çalışmada iki temel deney gerçekleştirilecektir:

Zamansal genelleme: Tek şehirli ve çok şehirli modellerin aynı şehirlerin gelecek dönemlerindeki tahmin performanslarının karşılaştırılması.

Coğrafi genelleme: Çok şehirli modellerin eğitim sırasında görmedikleri şehirlerdeki tahmin performanslarının değerlendirilmesi.

Model performansına etki eden faktörleri incelemek amacıyla geçmiş gözlem uzunluğu (24, 36 ve 60 ay), öğrenme oranı

(0.001 ve 0.0001) ve dropout oranı (0.0, 0.2 ve 0.4) üzerinde kontrollü deneyler gerçekleştirilecektir.

5 Baseline

Derin öğrenme modellerinin başarısını değerlendirmek amacıyla Zero-Anomaly Baseline kullanılacaktır. Bu yöntem, gelecek sıcaklık anomalilerinin sıfır olacağını varsaymaktadır.

Ayrıca her şehir için bağımsız olarak eğitilen Single-City LSTM, çok şehirli ortak öğrenmenin etkisini değerlendirmek amacıyla referans derin öğrenme modeli olarak kullanılacaktır.

6 Planlanan Derin Öğrenme Modelleri

Projede aşağıdaki derin öğrenme modelleri geliştirilecektir:

Single-City LSTM: Her şehrin yalnızca kendi tarihsel sıcaklık anomalileriyle eğitilen modeldir.

Multi-City LSTM: Birden fazla şehrin sıcaklık anomalileriyle ortak olarak eğitilen ve şehirler arasındaki ortak zamansal örüntüleri öğrenmeyi amaçlayan modeldir.

Multi-City GRU: LSTM'ye alternatif bir tekrarlayan sinir ağı mimarisi olarak kullanılacak ve farklı mimarilerin tahmin performansları karşılaştırılacaktır.

Geo-LSTM (Proposed Model): LSTM tarafından öğrenilen zamansal özelliklerin, şehirlerin enlem ve boylam bilgilerinden elde edilen coğrafi özelliklerle birleştirildiği modeldir. Bu yaklaşım, coğrafi bilginin tahmin performansına katkısını araştırmak amacıyla geliştirilecektir.

7 Değerlendirme Metrikleri

Modellerin performansı regresyon problemlerine uygun MAE, MSE, RMSE ve R^2 metrikleriyle değerlendirilecektir. Temel karşılaştırma metriği MAE olacaktır.

Ek olarak tahmin hataları şehir, coğrafi bölge ve tahmin ufku bazında analiz edilecektir. Eğitim ve doğrulama kayıp grafikleri üzerinden overfitting ve underfitting durumları incelenecektir.

Geo-LSTM modelinde coğrafi özelliklerin etkisini değerlendirmek amacıyla ablation study gerçekleştirilecek; Integrated Gradients yöntemiyle girdi özelliklerinin tahminler üzerindeki etkileri analiz edilecektir.

8 Beklenen Katkı

Bu çalışmanın temel katkısı, çok şehirli ortak öğrenmenin ve coğrafi konum bilgisinin sıcaklık anomalisi tahmin performansına etkisinin karşılaştırmalı deneylerle ortaya konulmasıdır.

Tek şehirli LSTM, çok şehirli LSTM, GRU ve Geo-LSTM modelleri karşılaştırılarak farklı öğrenme yaklaşımlarının avantajları ve sınırlılıkları değerlendirilecektir.

Ayrıca Geo-LSTM modelinin eğitim sırasında görmediği şehirlerdeki genelleme yeteneği araştırılacak ve coğrafi özelliklerin tahmin performansına katkısı analiz edilecektir.

Çalışmanın sonucunda, coğrafi bilgiyle desteklenmiş çok şehirli derin öğrenme yaklaşımlarının hangi koşullarda avantaj sağladığına ilişkin deneysel bulgular elde edilmesi hedeflenmektedir.

Kaynakça

Berkeley Earth. *Climate Change: Earth Surface Temperature Data*. Kaggle.
https://www.kaggle.com/datasets/berkeleyearth/climate-change-earth-surface-temperature-data

Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735–1780.
https://doi.org/10.1162/neco.1997.9.8.1735

Cho, K., et al. (2014). Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation. *Proceedings of EMNLP 2014*, 1724–1734.
https://doi.org/10.3115/v1/D14-1179